Atividade Prática 01

Metodologia Experimental

Guilherme Alvarenga de Azevedo
Maria Eduarda Teixeira Souza

CEFET-MG

Contextualização do Problema

O Problema: Segurança em transações financeiras digitais.

- **Cenário:** O aumento massivo de pagamentos eletrônicos exige sistemas de detecção que operem em tempo real para mitigar prejuízos financeiros.
- **Motivação:** Fraudadores utilizam técnicas sofisticadas (anéis de fraude, IPs dinâmicos) que dificultam a análise manual e exigem modelos robustos.

Contextualização do Problema

- **Objetivo do Experimento:**
  - Desenvolver uma metodologia reprodutível para identificação de fraudes.
  - **Tarefa de Classificação Binária:** Predizer se uma transação é *Legítima* ou *Fraudulenta*.
  - Avaliar o desempenho de diferentes algoritmos para otimizar a detecção.

Caracterização Geral da Base

Origem e Volume:

- Dataset sintético realista (1 milhão de instâncias).
- Janela: 2022 a 2024 (50k contas).

Taxonomia dos Atributos:

- **Nominal (7):** ex. ID, Categoria.
- **Discreto (6):** ex. Hora, Velocity.
- **Binário (6):** ex. Dispositivo conhecido.
- **Contínuo (4):** ex. Valor (Amount).

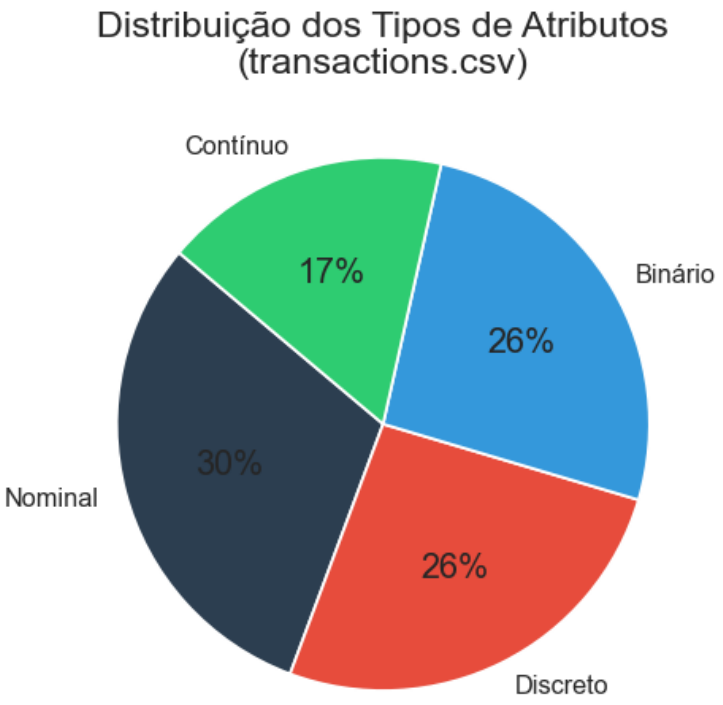

Figura: Diversidade de tipos exige pré-processamento distinto.

Desbalanceamento da Variável Alvo

O Desafio Realista:

- **Taxa de Fraude:** 1,71% (17.143 casos).
- **Razão:** 57,3 para 1.
- **Impacto:** Classes minoritárias exigem métricas como F1-Score e Recall em vez de Acurácia.

Sobre a base

Um modelo realista de geração de fraude probabilística que replica os principais padrões observados em operações de fraude do mundo real

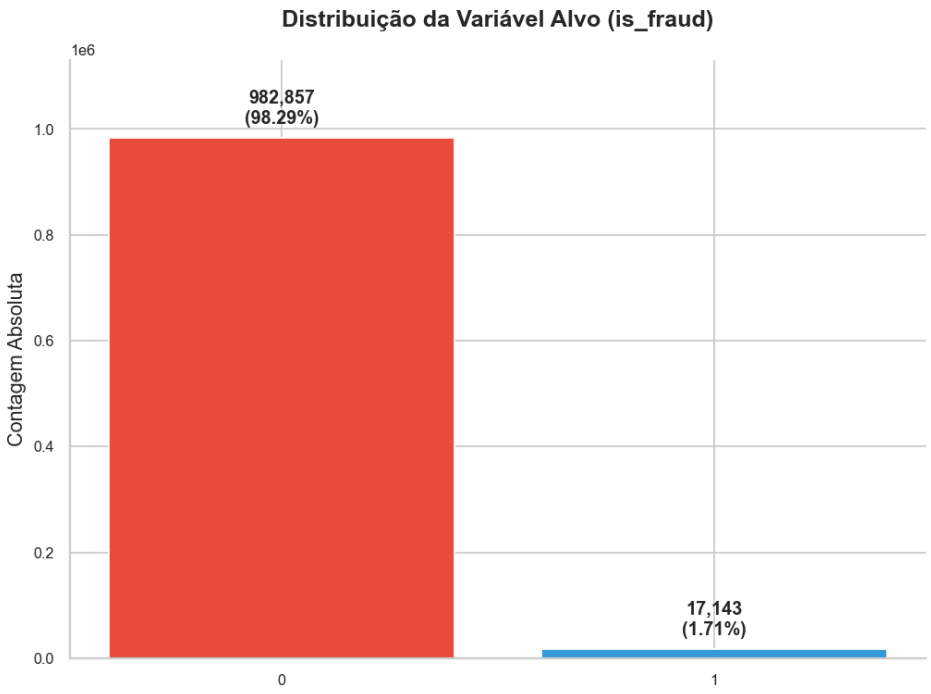

Figura: Severo desbalanceamento de classes.

Preditores e Assinaturas de Fraude

Correlações mais Fortes com *is_fraud*:

- `velocity_1h` **(+0.35)**: Transações rápidas aumentam o risco.
- `ip_risk_score` **(+0.27)**: Reputação do IP é determinante.
- `device_known` **(-0.19)**: Dispositivos novos são mais suspeitos.

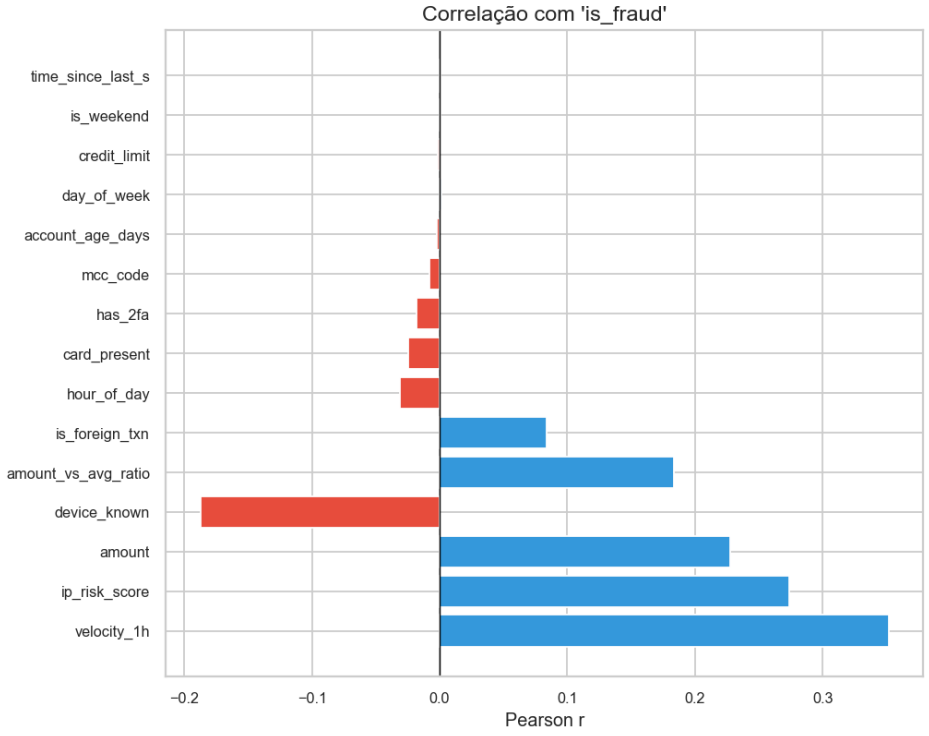

Figura: Comportamento estatístico das variáveis preditoras.

Qualidade e Saúde dos Dados

Integridade:

- **Nulos:** Presentes apenas em `fraud_pattern` (ausência lógica para transações legítimas).
- **Outliers:** Sob controle ($< 5\%$), indicando estabilidade na coleta.
- **Ação:** Necessária normalização devido à forte assimetria (*Skewness*).

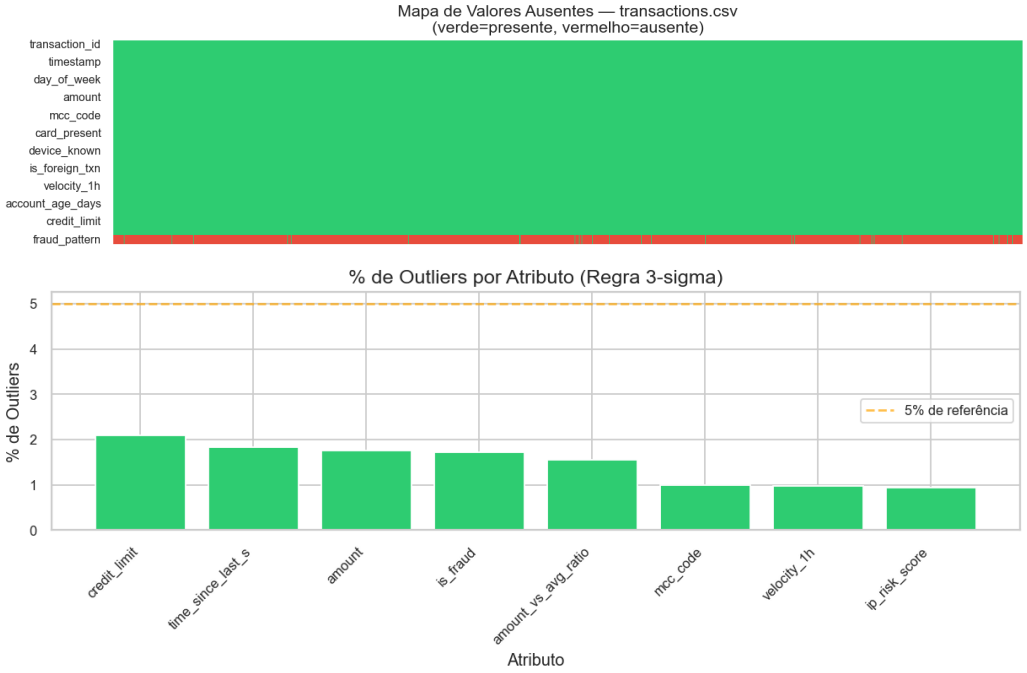

Figura: Diagnóstico de ruído para pré-processamento.

Preparação e Transformação dos Dados

Seleção de Atributos:

- **Remoção de IDs:** `transaction_id` e `account_id` (sem poder preditivo).
- **Target Leakage:** Exclusão de `fraud_pattern` para evitar que o modelo "trapaceie"com o gabarito.
- **Redundância:** Remoção de `timestamp`, `is_weekend`, `amount` e `mcc_code`.

Codificação Categórica:

- **One-Hot Encoding:** Aplicado em variáveis nominais sem ordem lógica.
- **Alvos:** *merchant_category*, *country* e *device_type*.
- **Objetivo:** Compatibilidade numérica para algoritmos como XGBoost.

Resultados

Base transformada de 23 para 43 dimensões após o encoding.

Justificativas e Estratégia

Por que manter o desbalanceamento e os outliers?

- **Realismo de Produção:** Manter 1,71% de fraude preserva os padrões reais de comportamento. O *undersampling* descartaria informações valiosas.
- **Tratamento de Nulos:** A remoção de `fraud_pattern` (vazamento) eliminou automaticamente 100% dos valores ausentes da base.
- **Estabilidade Estatística:** A regra 3-sigma confirmou que outliers representam <5% da base, não sendo destrutivos para o aprendizado.
- **Amostragem Estratificada:** O uso de `stratify` e `StratifiedKFold` garantiu a manutenção da proporção exata da classe minoritária (1,71%) em todas as partições, evitando enviesamento ou *folds* sem exemplos de fraude.

Estratégia de Avaliação

Lidar com o desafio realístico através de **métricas imunes** (F1-Score e

Modelos de Ensemble: RF e XGBoost

Random Forest:

- **Robustez**: Ensemble de árvores de decisão que captura padrões não-lineares complexos.
- **Pipeline**: Dispensa a necessidade de normalização prévia dos atributos.

XGBoost:

- **Performance**: Algoritmo estado da arte para dados tabulares estruturados.
- **Otimização**: Lida eficientemente com o desbalanceamento de classes.

Poder Preditivo

Capacidade de identificar cruzamentos complexos entre variáveis (ex: relação entre horário, valor e risco de IP).

Modelo Baseline: Regressão Logística

Abordagem Experimental:

- **Configuração**: Utilizada como *baseline* linear para comparar com modelos complexos.
- **Experimento Comparativo**: Executada de duas formas:
  - **Cenário A**: Sem normalização dos dados.
  - **Cenário B**: Com normalização (StandardScaler).

Objetivos da Escolha:

- Servir como modelo de referência simples e interpretável.
- **Impacto da Escala**: Demonstrar na prática como algoritmos baseados em equações matemáticas sofrem com atributos em escalas distintas.
- Validar a eficácia do pipeline de tratamento de dados.

Resultados: Validação Cruzada (5-Folds)

Estabilidade dos Modelos:

Modelo	**PR-AUC Médio**
Random Forest	**0.8259 (±0.0058)**
XGBoost	0.8013 (±0.0104)
Regressão Logística (Normalizada)	0.7920 (±0.0041)
Regressão Logística (Sem Normalização)	0.7641 (±0.0111)

Tabela: Média e Desvio Padrão após 5-folds.

- **Consistência:** Baixo desvio padrão indica modelos robustos e sem *overfitting*.
- **Impacto Teórico:** A normalização elevou a performance da Regressão Logística em quase 3%.

Distribuição de Performance (K-Fold)

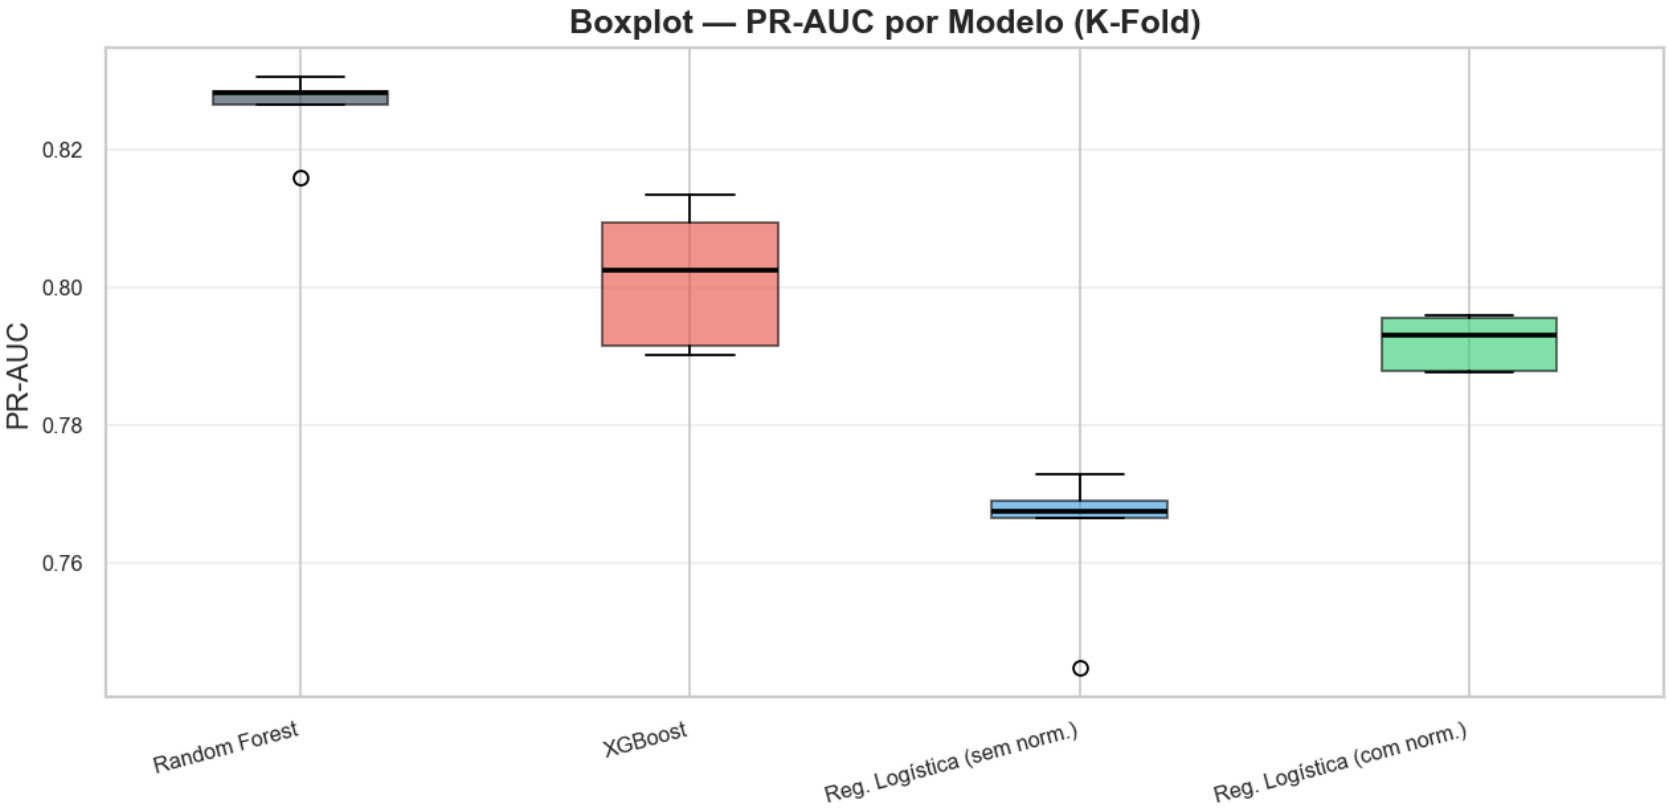

Figura: Boxplot comparativo de PR-AUC por modelo.

Teste Final e Métricas de Negócio

Desempenho Geral no Conjunto de Teste:

- **Acurácia (99%):** Desconsiderada por não refletir a eficácia na classe minoritária (fraude).
- **F1-Score:** XGBoost (**0.7293**) levemente superior ao Random Forest (0.7239).
- **PR-AUC:** Random Forest (**0.8158**) vs XGBoost (0.7805).

Métrica de Operação (P@80%Recall)

O Random Forest atingiu **63,78%** de precisão ao capturar 80% das fraudes, superando os 59,68% do XGBoost.

Resultados: Comparação Detalhada de Métricas

Desempenho dos Modelos no Conjunto de Teste:

Modelo	Acurácia	Precisão	Recall	F1-Score	PR-AUC	KS Stat.	P@80%R	ROC-AUC
Random Forest	**0.9919**	**0.8767**	0.6165	0.7239	**0.8158**	**0.8953**	**0.6378**	0.9850
XGBoost	0.9916	0.8137	**0.6608**	**0.7293**	0.7805	0.8940	0.5968	0.9857
Reg. Log. (sem norm.)	0.9906	0.8037	0.6005	0.6874	0.7541	0.8645	0.4889	0.9832
Reg. Log. (com norm.)	0.9913	0.8343	0.6169	0.7093	0.7806	0.8886	0.5362	**0.9879**

- **P@80%Recall:** Precisão do modelo quando configurado para detectar 80% das fraudes.
- O **Random Forest** destaca-se nas métricas de negócio (PR-AUC e P@80%R).

Curvas ROC e Precisão-Revocação (PR)

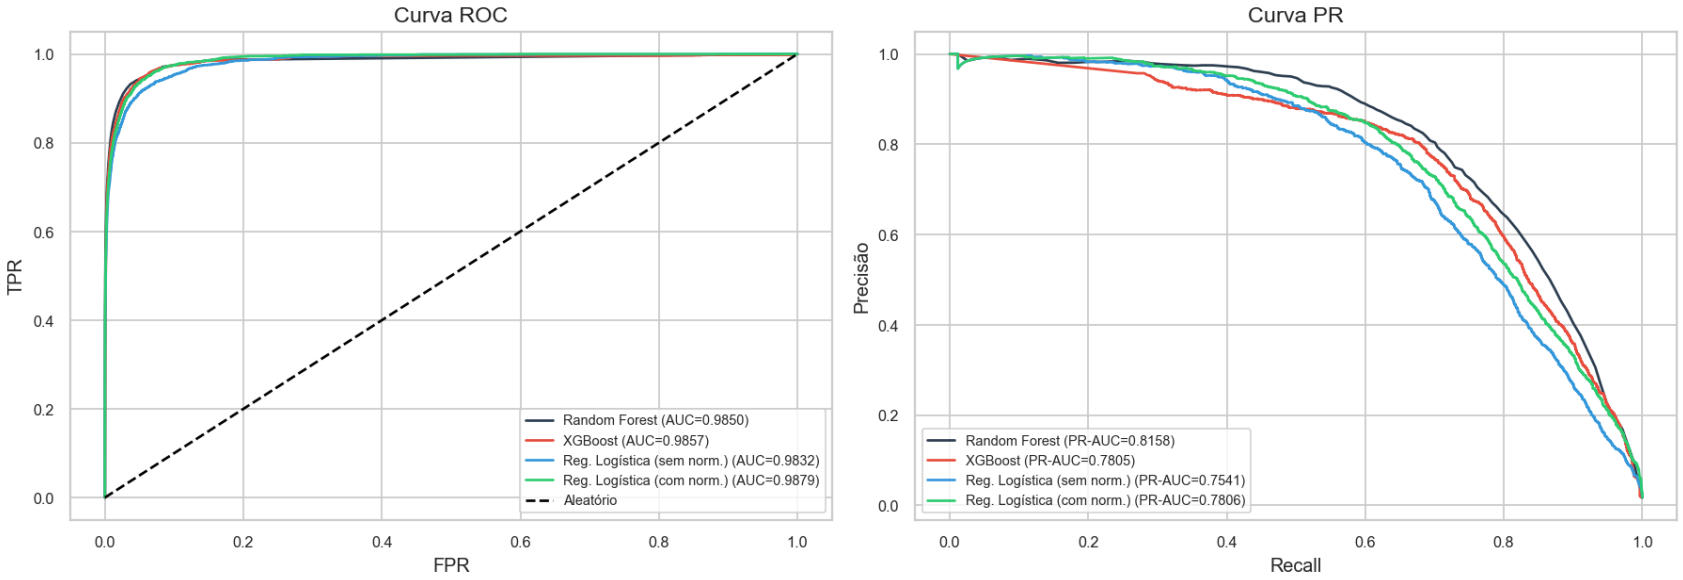

Figura: A curva PR (à direita) evidencia a superioridade do Random Forest.

Análise de Erros e Falsos Positivos

Trade-off entre Modelos:

- **XGBoost:** Maior Recall (1.699 fraudes detectadas), porém gera **389 falsos alertas**.
- **Random Forest:** Mais conservador e preciso. Detecta 1.585 fraudes com apenas **223 falsos positivos**.

Conclusão Crítica:

- O Random Forest reduz o atrito com clientes legítimos e a sobrecarga da equipe de revisão humana, sendo o modelo mais equilibrado para produção.

Detalhamento das Matrizes de Confusão

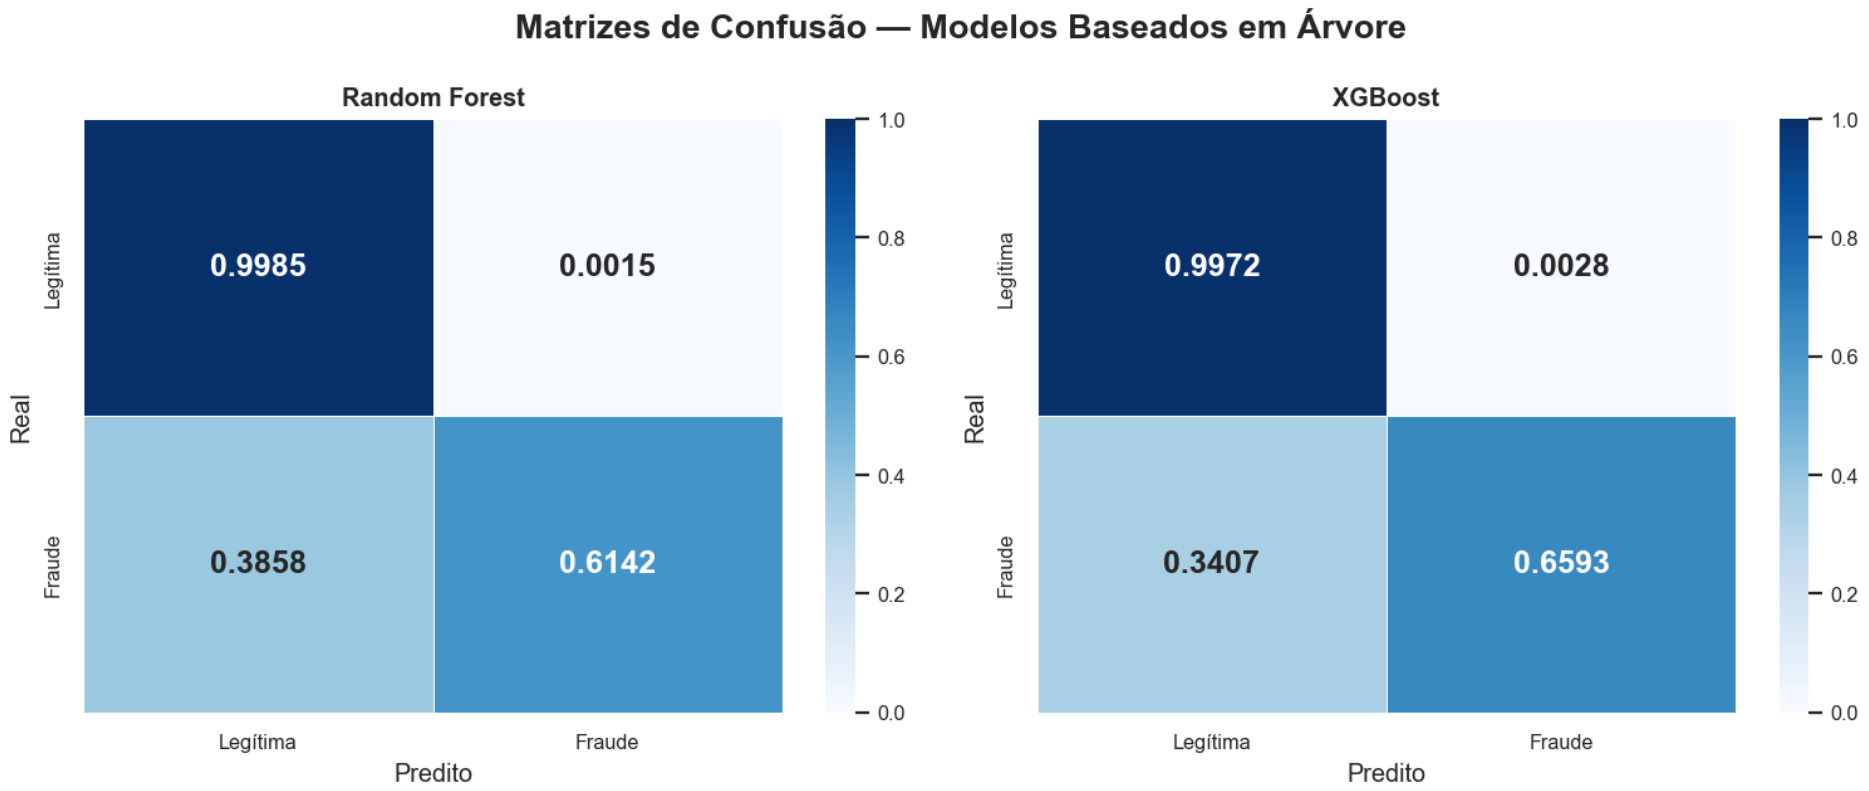

Figura: Comparação de Falsos Positivos e Falsos Negativos - Random Forest e XGBoost.

Detalhamento das Matrizes de Confusão

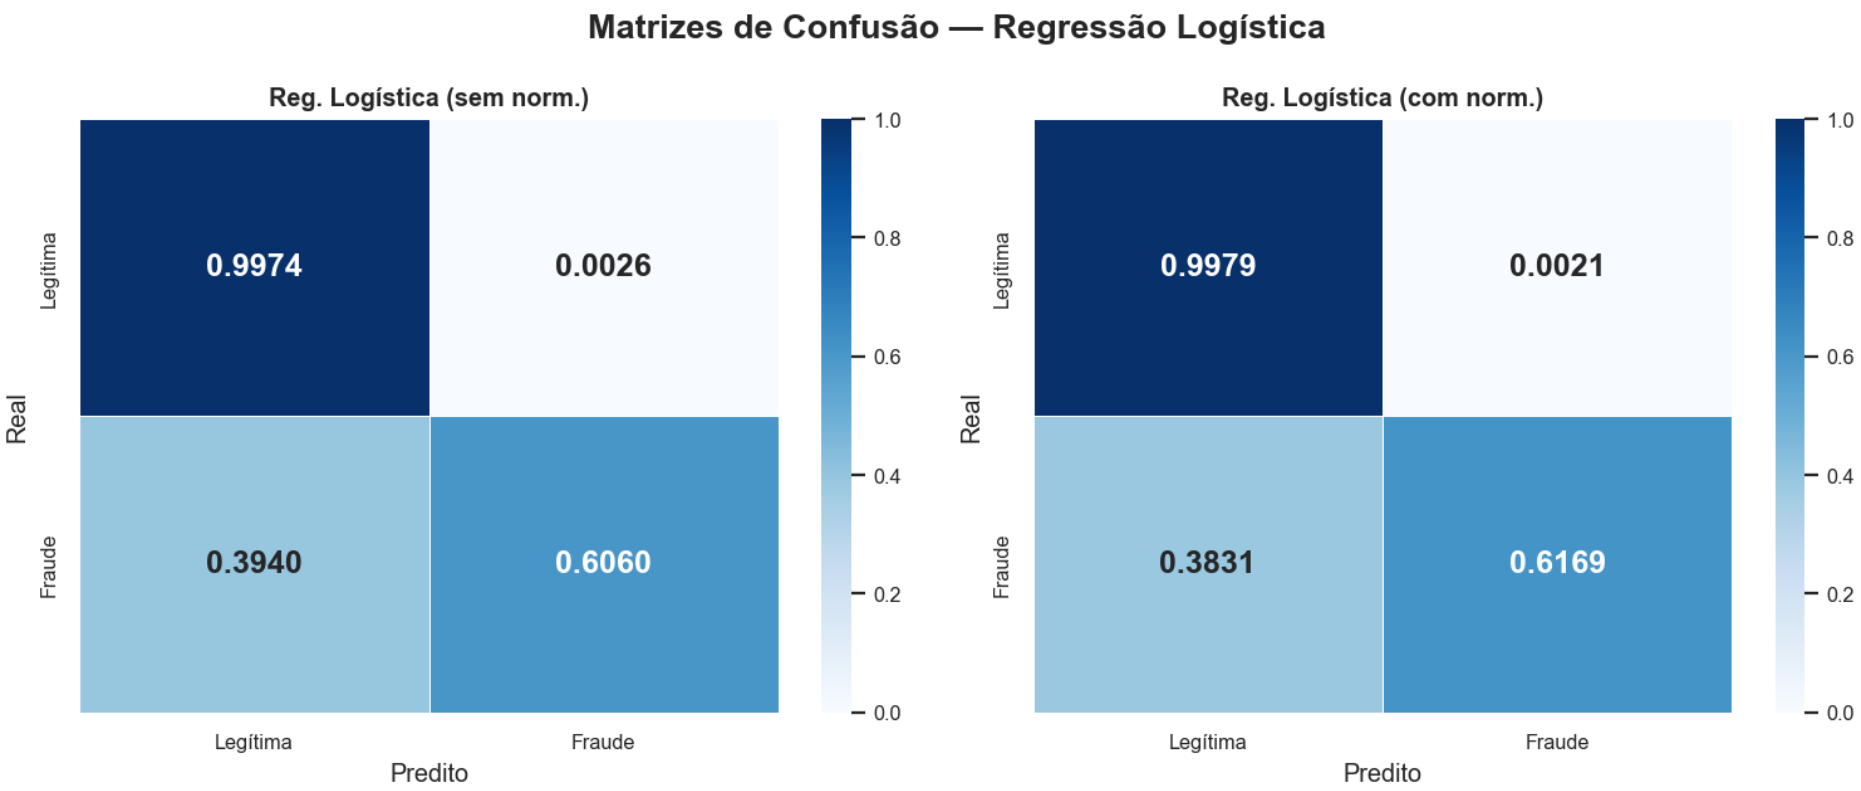

Figura: Comparação de Falsos Positivos e Falsos Negativos - Regressão Logística.

Discussão e Análise Crítica

- **Métricas Enganosas:** Acurácia (≈99%) e ROC-AUC (>98%) mascaram o desempenho real em bases desbalanceadas (1,71% de fraude).
- **Avaliação Definitiva:** A **Curva PR** revelou a verdadeira capacidade de detecção de cada modelo.
- **Custo de Negócio:** Embora o XGBoost tenha maior Recall, ele gerou 74% mais alertas falsos (389 vs. 223 do RF).
- **Atrito com o Cliente:** O alto volume de falsos positivos do XGBoost aumenta o atrito com clientes legítimos e a sobrecarga operacional.

Conclusão e Aprendizados

- **Vencedor para Produção:** O **Random Forest** consolidou-se como a melhor escolha pelo PR-AUC global (0,8158) e precisão cirúrgica.
- **Validação Teórica:** A normalização foi vital apenas para o modelo linear (Regressão Logística), comprovando a robustez dos *ensembles* de árvores.
- **Rigor Metodológico:** A decisão de não balancear a base artificialmente permitiu validar o modelo em um cenário realístico de produção.

Conclusão Final

O ajuste do limite de decisão em uma base realística (1,71% de fraude) resultou em um sistema preciso e pronto para operação.

Trabalhos Futuros e Limitações do Escopo

- **Redução de Dimensionalidade (PCA/LDA):** Optou-se por não aplicar estas técnicas visto que a base resultou em apenas 43 dimensões. Modelos baseados em árvores processam este volume com alta eficiência sem perda de interpretabilidade.
- **Amostragem de Dados:** Manteve-se a base massiva de 1 milhão de instâncias para priorizar o realismo. O *undersampling* descartaria padrões legítimos e descaracterizaria a taxa real de fraude de 1,71%.
- **Otimização de Hiperparâmetros:** Devido ao alto custo computacional de processar 1 milhão de instâncias em 5-folds, priorizou-se a correta validação cruzada em detrimento de buscas exaustivas (Grid Search).
- **Algoritmo de Cotovelo (para algoritmos de agrupamento - *Clustering*):** Técnica não utilizada pois o problema foi modelado estritamente como uma Classificação Supervisionada.

Justificativa Metodológica

As limitações impostas visaram garantir a validade estatística e o realismo do pipeline de produção, focando na qualidade do pré-processamento e da avaliação.

Referências I

1. AZEVEDO, Guilherme A.; SOUZA, Maria E. T. **FRAUD-DETECTION-IC**: Atividade Prática 01 - Metodologia Experimental. 2026. Disponível em: `https://github.com/alvarengazv/fraud-detection-ic`. Acesso em: 31 mar. 2026.
2. SILVA, Alisson M. **Inteligência Computacional**: Dados. Slides de Aula. 2026.
3. SILVA, Alisson M. **Inteligência Computacional**: Metodologia dos Experimentos. Slides de Aula. 2026.
4. SILVA, Alisson M. **Inteligência Computacional**: Experimentos. Slides de Aula. 2026.

Dúvidas?

Muito obrigado!

guilherme@aluno.cefetmg.br
maria@aluno.cefetmg.br